Laporan Analisis Komponen Utama (PCA) pada Dataset Weather Type Classification

Muhammad Fathir Rizqy Fadli
NIM: 10322005

17 September 2025

Daftar Isi

1 Dataset **2**

2 Deskripsi Data **2**

3 Metode **2**
3.1 Pra-pemrosesan Data 2
3.2 Analisis Korelasi dan PCA 2
3.3 Principal Component Analysis (PCA) 3

4 Hasil Analisis **4**
4.1 Statistik Fitur 4
4.2 Korelasi antar fitur 4
4.3 Scree Plot 6
4.4 Hasil PCA 6

5 Kesimpulan **7**

1 Dataset

Dataset yang digunakan dalam analisis ini adalah Weather Type Classification. Dataset ini diperoleh dari Kaggle, berisi 13200 observasi dengan 11 fitur yang mendeskripsikan data cuaca.

Tabel 1: Contoh Data Cuaca

Index	**Temp.**	**Humidity**	Wind Speed	Precip. (%)	**Cloud Cover**	Atm. Press.	UV Index	**Season**	Vis. (km)	**Location**	**Weather**
0	14	73	9.5	82	partly cloudy	1010.82	2	Winter	3.5	inland	Rainy
1	39	96	8.5	71	partly cloudy	1011.43	7	Spring	10.0	inland	Cloudy
2	30	64	7.0	16	clear	1018.72	5	Spring	5.5	mountain	Sunny
3	38	83	1.5	82	clear	1026.25	7	Spring	1.0	coastal	Sunny
4	27	74	17.0	66	overcast	990.67	1	Winter	2.5	mountain	Rainy

2 Deskripsi Data

Variabel-variabel yang terdapat dalam dataset dijelaskan pada Tabel 2.

Tabel 2: Deskripsi Variabel dalam Dataset

Variabel	**Tipe Data**	**Deskripsi Singkat**
Temperature	Numerik	Temperatur dalam celcius
Humidity	Numerik	Persentase Humidity
Wind Speed	Numerik	Kecepatan angin (km/h)
Precipitation	Numerik	Curah Hujan
Cloud Cover	Katerogikal	Tutupan Awan
Atmospheric Pressure	Numerik	Tekanan Atmosfer
UV Index	Numerik	UV Index
Season	Kategorikal	Musim
Visibility	Numerik	Visibilitas
Location	Kategorikal	Lokasi
Weather Type	Kategorikal	Tipe Cuaca

3 Metode

3.1 Pra-pemrosesan Data

Sebelum dilakukan analisis PCA, data perlu melalui tahap pra-pemrosesan. Langkah terpenting adalah mencari data yang kosong atau duplikat, setelah itu baru dilakukan analisis outlier menggunakan boxplot yang nantinya akan dibersihkan menggunakan metode Interquartile Range.

3.2 Analisis Korelasi dan PCA

Pada tahap ini, dilakukan analisis mendalam terhadap dataset klasifikasi cuaca untuk memahami hubungan antar variabel dan mengurangi dimensi data. Proses ini mencakup

analisis korelasi untuk mengidentifikasi hubungan linear antar fitur dan Principal Component Analysis (PCA) untuk mentransformasi data ke dalam ruang fitur yang lebih sederhana.

Langkah pertama adalah melakukan analisis korelasi untuk mengidentifikasi sejauh mana variabel-variabel dalam dataset saling berhubungan secara linear. Sebelum menghitung korelasi, variabel-variabel kategorikal seperti Cloud Cover, Season, dan Location diubah menjadi format numerik menggunakan Label Encoding.

Visualisasi dari matriks korelasi disajikan dalam bentuk **Heatmap**.

3.3 Principal Component Analysis (PCA)

PCA digunakan untuk mengurangi jumlah variabel dalam dataset (reduksi dimensi) sambil tetap mempertahankan sebagian besar informasi atau varians dari data asli. Proses ini sangat berguna untuk menyederhanakan model dan mempercepat proses komputasi.

Berikut tahapan untuk melakukan PCA:

1. **Standardisasi Data:** Seluruh fitur numerik distandardisasi menggunakan StandardScaler agar memiliki mean 0 dan standar deviasi 1. Langkah ini krusial agar fitur dengan skala yang lebih besar tidak mendominasi proses PCA.

2. **Ekstraksi Komponen:** PCA dijalankan untuk mengekstrak komponen utama dari data yang telah distandardisasi.

4 Hasil Analisis

4.1 Statistik Fitur

Tabel 3: Statistik Deskriptif Variabel Cuaca

Statistik	**Temp.**	**Humidity**	Wind Speed	Precip. (%)	Atmospheric Pressure	UV Index	Visibility (km)
count	13200	13200	13200	13200	13200	13200	13200
mean	19.13	68.71	9.83	53.64	1005.83	4.01	5.46
std	17.39	20.19	6.91	31.95	37.20	3.86	3.37
min	-25.0	20.0	0.0	0.0	800.12	0.0	0.0
25%	4.0	57.0	5.0	19.0	994.80	1.0	3.0
50%	21.0	70.0	9.0	58.0	1007.65	3.0	5.0
75%	31.0	84.0	13.5	82.0	1016.77	7.0	7.5
max	109.0	109.0	48.5	109.0	1199.21	14.0	20.0

4.2 Korelasi antar fitur

Didapat hasil dari perhitungan korelasi disajikan pada Gambar 1.



Gambar 1: Plot Korelasi antar fitur

Ada beberapa hal menarik yang bisa kita lihat dari korelasi ini

1. **Korelasi Positif Signifikan:**
   Terdapat hubungan positif yang sangat kuat antara Temperature dan UV Index. Hal ini mengindikasikan bahwa kenaikan suhu cenderung diiringi dengan kenaikan tingkat indeks UV.

   Humidity dan Precipitation (%) menunjukkan korelasi positif yang moderat. Ini menyiratkan bahwa tingkat kelembapan udara yang lebih tinggi cenderung berkaitan dengan kemungkinan precipitation yang lebih tinggi pula.

2. **Korelasi Negatif Signifikan:**
   Ditemukan korelasi negatif yang sangat kuat antara **Temperature** dan **Humidity**. Ini menunjukkan hubungan yang berbanding terbalik, di mana pada umumnya, saat suhu udara meningkat, tingkat kelembapan relatif cenderung menurun.

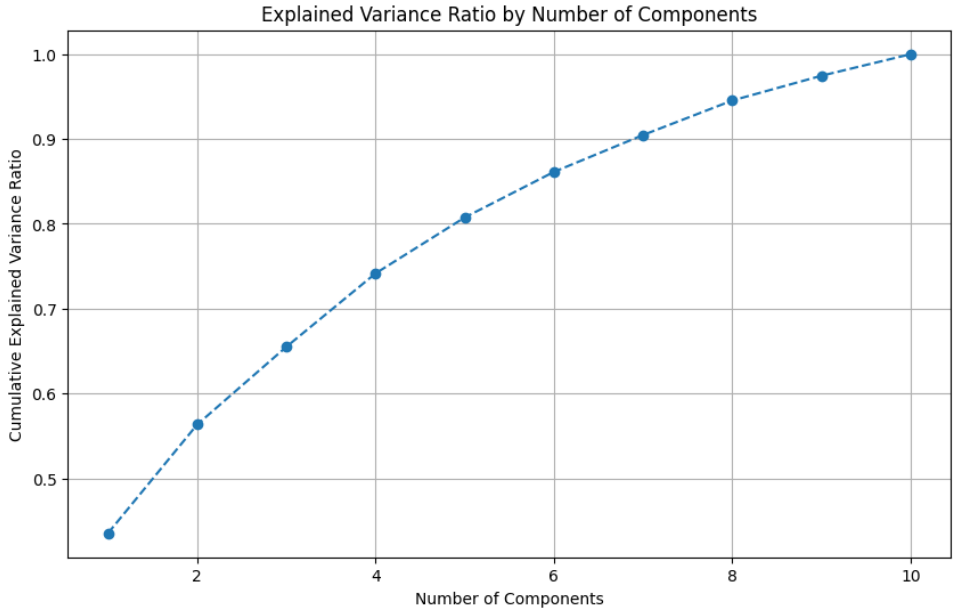
   Terdapat korelasi negatif yang cukup kuat antara **Humidity** dan **UV Index**. Udara yang lebih lembap seringkali diasosiasikan dengan kondisi lebih berawan,

yang dapat mengurangi intensitas radiasi UV yang mencapai permukaan.

Atmospheric Pressure memiliki korelasi negatif moderat dengan **Precipitation (%)**. Ini sesuai dengan teori cuaca di mana area bertekanan rendah seringkali menjadi pertanda akan datangnya hujan atau presipitasi.

4.3 Scree Plot

Berikut adalah scree plot nya



Gambar 2: Scree Plot

Kriteria yang digunakan untuk memilih jumlah komponen adalah dengan menetapkan ambang batas varians kumulatif yang ingin dipertahankan. Dalam analisis ini, ditetapkan bahwa model harus mampu menjelaskan **minimal 90%** dari total varians data asli untuk memastikan tidak ada kehilangan informasi yang signifikan.

Berdasarkan garis varians kumulatif pada plot, dapat disimpulkan bahwa:
Diperlukan **7 komponen utama** (PCA1 hingga PCA7) untuk melampaui ambang batas 90% dari total varians yang dijelaskan.

4.4 Hasil PCA

Tabel 4: Contoh Data Setelah Transformasi PCA

Index	PCA1	PCA2	PCA3	PCA4	PCA5	PCA6	PCA7
0	1.2979	-0.1231	0.3809	-0.2502	0.5333	0.8397	0.2763
1	-0.8601	-1.4293	0.4873	0.9008	0.3543	1.5381	-0.3899
2	-1.9393	0.6053	-1.4343	0.8600	-0.8456	-0.0905	-0.6657
3	-1.1937	-1.2652	-1.7007	-1.3651	-2.2908	1.8349	0.4351
4	1.8956	0.1239	-1.0649	0.6208	0.8565	-0.0871	-0.1034

5 Kesimpulan

Principal Componen Analysis pada dataset Weather Type Classification telah berhasil mereduksi dimensi data dari 11 menjadi 8.

Referensi

Pustaka

[1] https://www.kaggle.com/datasets/nikhil7280/weather-type-classification/data

[2] https://colab.research.google.com/drive/1rYU1XQndigvrplzxD66g9iyPp8KEGKKD?usp=sharing